DataSan. Документация, содержащая информацию, необходимую для эксплуатации экземпляра ПО

Перфоманс Лаб Сервисез



Содержание

Введение	3
Функциональные характеристики	3
О документации	3
Архитектура	5
Минимальные требования к аппаратному и программному обеспечению	6
Требования к серверам	6
Требования к сетям	6
Требования к рабочему месту	6
Установка DataSan для PostgreSQL	7
Поставка ПО	7
Компиляция	7
Настройка разрешений	9
Профилирование	9
Запуск деперсонализации в PostgreSQL	.13
Логирование	.14
Решение проблем для PostgreSQL	.16
Проблемы при установке	.16
Проблемы при профилировании	.16
Проблемы при запуске деперсонализации	.17
Перечень терминов и сокращений	.18

Введение

DataSan – инструмент для деперсонализации конфиденциальной информации и персональных данных в БД с сохранением работоспособности системы.

Функциональные характеристики

DataSan предоставляет пользователю следующие функциональные возможности:

- деперсонализация конфиденциальной информации и персональных данных в базах данных PostgreSQL с сохранением работоспособности системы и консистентности данных;
- защита данных за счет кодирования:
 - хэширование основной метод кодирования, реализованный на основе метода хэширования MD5;
 - маппинг метод кодирования, реализованный на основе сопоставления символов;
- добавление функций для обработки:
 - уникальных типов данных, например, ОГРН и ИНН;
 - динамических типов данных, например, транслитерация ФИО;
- добавление функций обработки данных в общий процесс деперсонализации базы данных;
- возобновление деперсонализации базы данных после прерывания процесса, например, при выключении электричества.
 Деперсонализация продолжится с данных, на которых процесс был прерван;
- многопоточность, которая позволяет использовать инструмент в многоядерных конфигурациях стенда для ускорения процесса деперсонализации;
- очистка вспомогательных объектов по окончании процесса деперсонализации данных;
- встраивание деперсонализации базы данных в процессы разработки.

О документации

Руководство по эксплуатации предназначено для инженеров нагрузочного и функционального тестирования. После прочтения руководства инженеры смогут:

- установить ПО DataSan;
- запустить деперсонализацию БД;

• проследить за процессом деперсонализации.

Чтобы эффективно использовать DataSan, рекомендуется ознакомиться с работой сервисов и программных продуктов:

- СУБД PostgreSQL;
- среда разработки DBeaver.

Если вам требуется помощь, свяжитесь с нами.

Архитектура

ПО DataSan представляет собой набор PL/pgSQL-скриптов и Java-классов, которые деперсонализируют конфиденциальную информацию и персональные данные в БД.

Деперсонализированная БД системы удовлетворяет следующим требованиям:

- из БД невозможно получить конфиденциальную информацию о физических или юридических лицах;
- система функционально корректно работает с данной БД.

ПО DataSan состоит из следующих структурных элементов:

Название элемента	Описание
PL/pgSQL-скрипты	Реализуют подготовительные операции с БД, управляют процессом деперсонализации и применением методов кодирования
СУБД PostgreSQL	СУБД на сервере заказчика, для данных которой выполняется деперсонализация
Java-классы	Реализуют методы кодирования для разных типов данных

Соединение выбранных структурных элементов представлено на схеме:



Минимальные требования к аппаратному и программному обеспечению

Требования к серверам

Процессор	2 ядра с частотой 2,5 ГГц
Оперативная память	От 8 Гбайт
HDD для IIS и документов	От 50 Гбайт. Зависит от размера хранимых в системе документов
SSD для SQL	От 300 Гбайт
СУБД	PostgreSQL 7 и выше
Установленные расширения для СУБД PostgreSQL	PL/JAVA, pgAgent

Требования к сетям

Скорость передачи данных	От 10 Мбит/с
--------------------------	--------------

Требования к рабочему месту

Установленное ПО DBeaver

Установка DataSan для PostgreSQL

Общий порядок установки DataSan для PostgreSQL включает следующие этапы:

- 1. Перед установкой ознакомьтесь с <u>типовыми требованиями к</u> аппаратному и программному обеспечению.
- 2. Получите экземпляр ПО.
- 3. Скомпилируйте проект.
- 4. <u>Настройте разрешения для пользователя</u>, под которым будет запускаться деперсонализация БД.
- 5. Выполните профилирование БД.

Поставка ПО

В рамках поставки клиент получает экземпляр ПО и документацию, которая подробно и понятно описывает эксплуатацию ПО, его настройку, устранение типичных неисправностей и частые вопросы, возникающие у пользователей в процессе эксплуатации.

Экземпляр ПО – 7Z-архив, который содержит файлы для компиляции в среде разработки:

- 1_Create_Java.sql алгоритмы обезличивания на языке Java;
- 2 Create jproc.sql методы обезличивания на языке Java;
- 3_Create_Object.txt вспомогательные таблицы;
- 4_Pflb_Datasan.txt пакет с процедурами DataSan;
- 5.prep proce.txt процедуры для создания таблицы **PFLB VIEWCONTENT**;
- 6.prep code.txt алгоритм для выполнения процедур PFLB_VIEWCONTENT;
- 7_Body.txt движок DataSan.

Компиляция

Чтобы скомпилировать проект:

- 1. Распакуйте 7Z-архив с экземпляром ПО.
- 2. Запустите среду разработки, например, DBeaver.
- 3. В контекстном меню БД выберите пункт **Connect**.
- 4. Укажите данные для подключения к БД и нажмите на кнопку **Connect**.
- 5. Последовательно скомпилируйте все файлы из 7Z-архива с экземпляром ПО:
 - А. Откройте файл для компиляции и скопируйте его содержимое.
 - В. В IDE в область Worksheet вставьте содержимое файла.

С. Выделите текст с помощью горячих клавиш CTRL+A и нажмите на кнопку .

После компиляции структура проекта выглядит следующим образом:

- Tables:
 - PFLB ACTIVE JOBS;
 - PFLB_ACTIVE_STATUS;
 - PFLB_ALL_TAB_INDEXES;
 - PFLB_ALL_TRIGGERS;
 - PFLB_CURRENT_STATUS;
 - PFLB_EVEN_TABLES;
 - PFLB_JOB_PROCESSED_QUERIES;
 - PFLB LOGS;
 - PFLB LT DEPERSONTABLES;
 - PFLB_NOT_PROCESSED_JOBS;
 - PFLB_PROCESSED_QUERIES;
 - PFLB TABLE SIZE;
 - PFLB_TABLE_TRIGGERS;
 - PFLB_TEMP_TABLE_INDEXES;
 - PFLB_VIEWCONTENT;

Packages:

- PFLB_DATASAN;
- PFLB_DATASAN_PREP;
- Functions:
 - PFLB ENCODE HASH BDATE;
 - PFLB_ENCODE_HASH_BINARY;
 - PFLB_ENCODE_HASH_CARDNUMBER;
 - PFLB ENCODE HASH CDATE;
 - PFLB_ENCODE_HASH_CHAR;
 - PFLB_ENCODE_HASH_CHARDEL;
 - PFLB_ENCODE_HASH_DATE;
 - PFLB_ENCODE_HASH_INNUMBER;
 - PFLB_ENCODE_HASH_IP;
 - PFLB ENCODE HASH NCHAR;
 - PFLB_ENCODE_HASH_OGRN;
 - PFLB_ENCODE_HASH_PHONENUMBER;
 - PFLB_ENCODE_HASH_PPCHAR;
 - PFLB ENCODE HASH SNILSNUMBER;
- Java:
 - BitConverter;
 - OraSQL.

Настройка разрешений

Настройте разрешения для пользователя, под которым будет запускаться деперсонализация БД:

```
GRANT ALL on schema PFLBTEST to PFLBUSER;
GRANT ALL ON ALL SEQUENCES IN SCHEMA PFLBTEST TO PFLBUSER;
GRANT USAGE ON LANGUAGE java TO PFLBUSER;
```

Профилирование

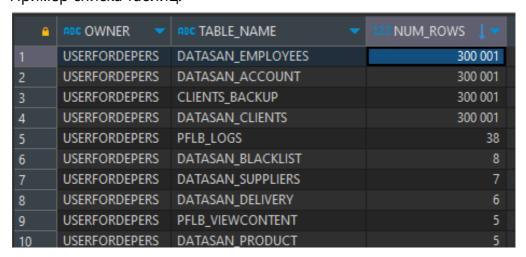
Профилирование – поиск колонок в таблицах в базе данных, содержащих персональные данные.

Чтобы выполнить профилирование БД:

- 1. Найдите таблицы и поля в БД, которые содержат персональные данные:
 - А. Получите список всех таблиц, соответствующих определенной схеме:

```
SELECT schemaname owner,relname table_name,n_live_tup num_rows
   FROM pg_stat_user_tables
   where schemaname='schema_name'
ORDER BY n_live_tup DESC;
```

Пример списка таблиц:



- В. Выберите таблицы с большим количеством строк. Рекомендуется выбирать таблицы, которые содержат более 10000 строк.
- С. Посмотрите содержимое каждой из найденных таблиц.
- D. Сохраните тип данных и названия полей, которые содержат персональные данные.
- 2. Соберите представления на основании найденных полей и выберите методы кодирования для каждого типа данных. Метод кодирования

указывается в конце наименования представления:

- **char** смешанные и неопределенные поля;
- chardel адреса и ФИО;
- nchar названия организации и ФИО;
- phonenumber номера телефонов;
- ppchar серия и номер паспорта;
- **bdate** дата рождения;
- inn umber ИНН;
- cdate даты в интервале за год до текущего дня;
- cardnumber номер банковской карты;
- ip IP-адреса.

Примеры:

• создание представления для поля **%E-MAIL**% и кодирование методом **char**.

```
create view PFLB_LT_Deperson_CommonEmail_CHAR
as
select C.*
from information_schema.columns c
inner join information_schema.tables t on c.table_name=t.table_name
where
    (C.COLUMN_NAME ILIKE '%EMAIL%' or C.COLUMN_NAME ILIKE '%E_MAIL%'
or C.COLUMN_NAME ILIKE '%E-MAIL%')
and C.DATA_TYPE = 'character varying';
```

• создание представления для поля **%INN%** и кодирование методом **inn umber**:

```
create view PFLB_LT_Deperson_Common_INNNUMBER
as
select C.*
from information_schema.columns c
inner join information_schema.tables t on c.table_name=t.table_name
where
    C.COLUMN_NAME ILIKE '%INN%'
and (C.DATA_TYPE = 'integer' or C.DATA_TYPE = 'numeric');
```

• создание представления для полей с названиями организаций и ФИО, их кодирование методом **nchar**:

```
create view PFLB_LT_Deperson_PhisFIO_NCHAR
as
select C.*
from information_schema.columns c
inner join information_schema.tables t on c.table_name=t.table_name
where
(c.table_name not like 'pflb%' and c.table_name not like
'viewcontent')
```

```
and
  C.COLUMN NAME ILIKE '%FIRST NAME%'
  or C.COLUMN NAME ILIKE '%LAST NAME%'
  or C.COLUMN_NAME ILIKE '%SECOND_NAME%'
  or C.COLUMN_NAME ILIKE '%MIDDLENAME%'
  or C.COLUMN NAME ILIKE '%PAYERNAME%'
  or C.COLUMN_NAME ILIKE '%RECIEVERNAME%'
  or C.COLUMN NAME ILIKE '%CLIENTFULLNAME%'
  or C.COLUMN NAME ILIKE '%PERSONFULLNAME%'
  or C.COLUMN NAME ILIKE '%PAYERFULLNAME%'
  or C.COLUMN_NAME ILIKE '%RECIEVERFULLNAME%'
  or C.COLUMN_NAME ILIKE '%BUYERFULLNAME%'
  or C.COLUMN_NAME ILIKE '%SELLERFULLNAME%'
  or C.COLUMN NAME ILIKE '%BENEFICAIARYFULLNAME%'
  or C.COLUMN_NAME ILIKE '%BOSSFULLNAME%'
  or C.COLUMN_NAME ILIKE '%KINFULLNAME%'
  or C.COLUMN_NAME ILIKE '%NAME%'
)
and C.DATA TYPE = 'character varying'
and C.TABLE SCHEMA != 'information schema';
```

- 3. Убедитесь, что поля в представлениях не повторяются, иначе в таблице для деперсонализации данных будут дублироваться строки.
- 4. Вставьте в промежуточную таблицу **PFLB_LT_DepersonTables** содержимое всех представлений. Например:

```
insert into PFLB_LT_DepersonTables values
('PFLB_LT_Deperson_CommonEmail_CHAR');
insert into PFLB_LT_DepersonTables values
('PFLB_LT_Deperson_Common_INNNUMBER');
insert into PFLB_LT_DepersonTables values
('PFLB_LT_Deperson_PhisFIO_NCHAR');
```

5. Запустите процедуру по наполнению основной таблицы для деперсонализации данных **PFLB VIEWCONTENT**:

```
CALL PFLB_DATASAN_PREP.PFLB_FILL_VIEWCONTENT('HASH');
```

Таблица **PFLB_VIEWCONTENT** наполнится записями вида имя_таблицы + наименование_колонки, которые ранее были собраны в представлениях. Пример наполненной таблицы **PFLB_VIEWCONTENT**:



- 6. Проанализируйте каждую строку таблицы **PFLB_VIEWCONTENT** и при необходимости скорректируйте ее:
 - удалите все дубликаты, неправильно выбранные методы, пустые или системные таблицы. Например:

OWNER_NAME	▼ RBC TABLE_NAME ▼		ABC COLUMN_TYPE	REC ENCODE_METHOD	ABE COLUMN_ENCODE_TYPE T	RBC EXAMPLE
TEST2_DB	DATASAN_CLIENTS	CLIENT_ADDRESS	VARCHAR	HASH	CHARDEL	554039, Тюменская область, город Н
TEST2_DB	DATASAN_CLIENTS	CLIENT_FULLNAME	VARCHAR	HASH	CHARDEL	Лихачёв Владимир Христофорович
TEST2_DB	DATASAN_CLIENTS	CLIENT_PHONE_NUMBER	VARCHAR	HASH	PHONENUMBER	7(477)196-49-67
TEST2_DB	DATASAN_CLIENTS	CLIENT_PASSPORT	VARCHAR	HASH	PPCHAR	0123 456789
TEST2_DB	DATASAN_CLIENTS	CLIENT_BIRTHDAY	DATE	HASH	BDATE	01.01.2021
TEST2_DB	DATASAN_CLIENTS	CLIENT_BIRTHDAY	DATE	HASH	BDATE	01.01.2021

• удалите таблицы, которые не содержат персональные данные. Например, таблица **DATASAN_LOGS** содержит колонку CLIENT_ADDRESS, но в этом поле нет персональных данных:

6 USERFORDEPERS DATASAN_LOGS CLIENT_ADDRESS VARCHAR HASH CHARDEL Случайный комент

Запуск деперсонализации в PostgreSQL

Чтобы запустить деперсонализацию БД, выполните процедуру PFLB_DATASAN.PFLB_PROCESS_DATA_TYPE:

CALL PFLB_DATASAN.PFLB_PROCESS_DATA_TYPE('Лицензионный ключ', 'Метод кодирования по умолчанию', 'Количество потоков', 'Количество строк', 'Режим работы');

Параметры процедуры:

- **Лицензионный ключ**. Ключ, который получает клиент после покупки ПО DataSan;
- **Метод кодирования по умолчанию**. Используется, если в таблице **PFLB_VIEWCONTENT** не указан метод кодирования. Возможные значения:
 - HASH. Хэширование основной метод кодирования, реализованный на основе метода хэширования MD5;
 - **MAPPING**. Маппинг метод кодирования, реализованный на основе сопоставления символов;
- **Количество потоков**. Количество потоков деперсонализации, запускаемых параллельно. Если ресурсы на сервере ограничены, укажите количество потоков равное количеству ядер;
- **Количество строк**. Количество строк таблицы для обработки внутри одного потока. Рекомендуется указать не менее 50000 и не более 300000;
- **Режим работы**. Возможные значения: **0** обычный режим, **1** режим отладки.

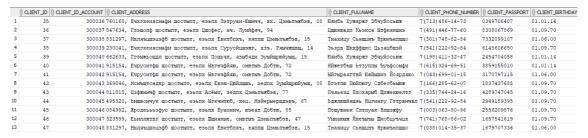
Пример запуска процедуры:

```
CALL PFLB_DATASAN.PFLB_PROCESS_DATA_TYPE((('1ACB-2387BD-4592', 'HASH', 64, 300000, 0);
```

Чтобы посмотреть список всех обезличенных таблиц, выполните запрос после завершения процесса деперсонализации:

```
SELECT *FROM PFLB_PROCESSED_QUERIES
```

После проведения деперсонализации удостоверьтесь, что все таблицы обезличены:



Note:

Данные после обезличиваниям методом хэширования не подлежат восстановлению.

Логирование

После запуска деперсонализации можно посмотреть общий лог процесса, статус и активные задания.

Общий лог деперсонализации

Чтобы посмотреть лог всего процесса, выполните запрос:

```
SELECT * FROM PFLB_logs ORDER BY id desc
```

В таблице **PFLB_logs** отображается текущий этап и таблица:

```
10 !@#$ Starting to update DATASAN_CLIENTS
9 !@#$ Disable indexes for DATASAN_CLIENTS
8 #index table is filled
7 Update string is created
6 clear #index table
5 !@#$ Generating update string for DATASAN_CLIENTS
4 !@#$ Start processing on DATASAN_CLIENTS
3 !@#$ Lic key is verificated
2 !@#$ enter to generate_update
```

Когда в таблице **PFLB_logs** появляются сообщения All temp columns dropped и exit from generate_update, процесс деперсонализации завершился, и все таблицы из **PFLB_VIEWCONTENT** обезличены:

```
39 !0#$ exit from generate_update
38 !0#$ All temp columns dropped
37 Checking temp_id_column on USERFORDEPERS.DATASAN_CLIENTS, start dropping it
36 !0#$ Start processing on DATASAN_CLIENTS
35 !0#$ Lic key is verificated
```

Активные задания

Чтобы посмотреть активные задания, выполните запрос:

SELECT * **FROM** PFLB_ACTIVE_JOBS

Если задания в таблице **PFLB_ACTIVE_JOBS** не меняются долгое время, то процесс деперсонализации остановился с ошибкой.

Статус процесса

Чтобы посмотреть статус процесса, выполните запрос:

SELECT * FROM PFLB_ACTIVE_STATUS

Если по завершению процесса таблица **PFLB_ACTIVE_STATUS** пуста, то процесс завершился без ошибок.

Если в таблице **PFLB_ACTIVE_STATUS** есть поле ERROR, то процесс завершился с ошибками. Посмотрите содержимое таблицы **PFLB_logs**. Подробнее см. раздел <u>Решение проблем</u>.

Решение проблем для PostgreSQL

Проблемы при установке

Недостаточно разрешений

Отсутствуют необходимые разрешения у пользователя, под которым запускается деперсонализация БД.

Решение:

Запросите необходимые разрешения у администратора БД. Подробнее см. раздел <u>Настройка разрешений</u>.

Таблица или представление пользователя отсутствует

Не были скомпилированы некоторые таблицы, представления или процедуры.

Решение:

- 1. Найдите, какие таблицы, представления или процедуры не были скомпилированы из списка всех вспомогательных таблиц.
- 2. Скомпилируйте необходимые таблицы, представления или процедуры повторно.

Подробнее см. раздел Компиляция.

Проблемы при профилировании

Неправильно выбран метод обезличивания данных

Решение:

Замените метод обезличивания через update в таблице **PFLB_VIEWCONTENT** на необходимый метод из списка методов. Подробнее см. раздел <u>Профилирование</u>.

Дубликаты в таблице PFLB_VIEWCONTENT

Решение:

- 1. Проверьте содержимое представлений и корректность списка колонок. Некоторые колонки дублируются или агрегируются неправильно из-за символов **%** в представлении.
- 2. Явно укажите название колонки или укажите название с помощью символов **%**, игнорируя символы до и после.
- 3. Удалите похожие колонки.

В таблицу PFLB_VIEWCONTENT попали колонки без

персональных данных

Возможные причины и решения:

- **PFLB_VIEWCONTENT** промежуточная таблица. На этапе профилирования в ней могли находиться персональные данные, но спустя время они были удалены. Рекомендуется оставить колонки.
- Колонки попали при создании представлений и таблицы PFLB_VIEWCONTENT. Проверьте колонки вручную и при необходимости удалите их.

Нет метода для определенного вида персональных данных

Решение:

Обратитесь в службу техподдержки ООО «Перфоманс Лаб Сервисез» по электронной почте datasan@pflb.ru.

Проблемы при запуске деперсонализации

Дублируется имя столбца

Решение:

- 1. К таблице **PFLB_VIEWCONTENT** выполните запрос с помощью оператора DISTINCT.
- 2. Удалите все дубликаты.

Неверное имя таблицы

Решение:

Проверьте правильность заполнения таблицы **PFLB_VIEWCONTENT** и найдите ошибку в имени таблицы.

Перечень терминов и сокращений бд

База данных

Деперсонализация БД

Обезличивание конфиденциальной информации в базе данных с сохранением работоспособности системы

Деперсонализация данных

Общее название любого процесса удаления связи между совокупностью идентифицирующих данных и субъектом данных

ИБ

Информационная безопасность

Обезличивание

Действия, в результате которых становится невозможным без использования дополнительной информации определить принадлежность персональных данных конкретному субъекту персональных данных (ФЗ N 152 "О персональных данных" от 27.07.2006, статья 3 пункт 9)

Персональные (личные) данные

Любая информация, относящаяся к прямо или косвенно определенному или определяемому физическому лицу (субъекту персональных данных) (ФЗ N 152 "О персональных данных" от 27.07.2006, статья 3 пункт 1)

ПО

Программное обеспечение

Профилирование

Поиск колонок в таблицах в базе данных, содержащих персональные данные.

СУБД

Система управления базой данных